自 然 语 言 处 理

第4章 文本向量化(中)

授课教师：李芳芳
联系方式：lifangfang@csu.edu.cn

本章教学内容

文本向量化

本章内容一览表（共计4学时）

每小节概要	每小节知识点	重难点
第1小节　前景概要	为什么要进行文本向量化?	否
第2小节　离散表示：词袋模型	四种词袋模型：Onehot、TF、TF-IDF、Ngram	**是**
第3小节　分布式表示：词嵌入	为什么要进行词嵌入?	否
第4小节　Word2Vec	Word2Vec进行文本向量化的原理、优缺点	**是**
第5小节　ELMO模型	ELMO进行文本向量化的原理、优缺点	**是**
第6小节　GPT模型	GPT进行文本向量化的原理、优缺点	**是**
第7小节　课堂小结	内容小结	否

本章教学内容

文本向量化思维导图



本章教学内容

文本向量化

本章内容一览表（共计4学时）

每小节概要	每小节知识点	重难点
第1小节　前景概要	为什么要进行文本向量化?	否
第2小节　离散表示：词袋模型	四种词袋模型：Onehot、TF、TF-IDF、Ngram	**是**
第3小节　分布式表示：词嵌入	为什么要进行词嵌入?	否
第4小节　NNLM、Word2Vec	NNLM、Skip-gram、CBOW	**是**
第5小节　ELMO模型	ELMO进行文本向量化的原理、优缺点	**是**
第6小节　GPT模型	GPT进行文本向量化的原理、优缺点	**是**
第7小节　课堂小结	内容小结	否

4 词嵌入之NNLM

词向量

- 我们人说一句话的时候，是一个词一个词蹦出来的，是不是可以已知某个/些词，**预测下一个词呢(NNLM)**?
- 或者已知某个词预测**周围的语境词(Word2Vec)**呢?
- 给定一句话：

the man who passes the sentence should swing the sword

1	2	3	4	5	6	7	8	9	10
the	man	who	passes	the	sentence	should	swing	the	sword
w_{nc1}	w_{nc2}	w_{nc3}	w_{c1}	w_{c2}	w_{center}	w_{c3}	w_{c4}	w_{nc4}	w_{nc5}

目标数学化：通过最大化给定中心词下相邻词的概率，间接获取词向量。

4 词嵌入之Word2Vec

Word2Vec

- Google的Mikolov在2013年推出了一款计算词向量的工具
- word2vec作为神经概率语言模型的输入，其本身其实是神经概率模型的副产品，是为了通过神经网络学习**某个语言模型**而产生的中间结果。具体来说，“某个语言模型”指的是“CBOW”和“Skip-Gram”。具体学习过程会用到两个降低复杂度的近似方法——Hierarchical Softmax或Negative Sampling。

4 词嵌入之Word2Vec

Word2Vec

- **Word2Vec**也是一种词嵌入模型，它的结构和NNLM基本类似，不过它们的重点不一样，NNLM重点在于预测概率，中间得到的词向量只是个副产物，而Wrod2Vec则把重点单纯放在了获取词向量上。
- Word2Vec中的两种重要模型：
  - 如果拿一个词的上下文作为输入，来预测这个词本身，则是“**CBOW**”。

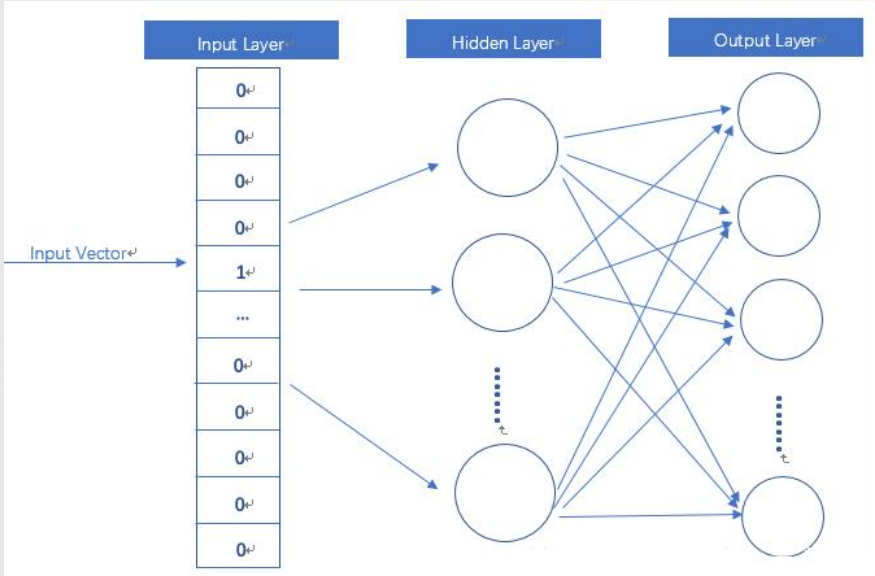
    优化方法：Hierarchical Softmax
  - 如果用一个词作为输入，来预测它周围的上下文，这个模型叫做“**Skip-gram**”；

    优化方法：负采样Negative Sampling

4 词嵌入之Word2Vec

Word2Vec

- word2vec模型其实就是简单化的神经网络。



- 网络结构：输入是One-Hot Vector，隐藏层没有激活函数，也就是线性单元。输出层维度跟输入层一样，用的是Softmax回归。
- 当这个模型训练好以后，我们并不会用这个训练好的模型处理新的任务，我们真正需要的是这个模型通过训练数据所学得的参数：隐层的权重矩阵。

4 词嵌入之Word2Vec

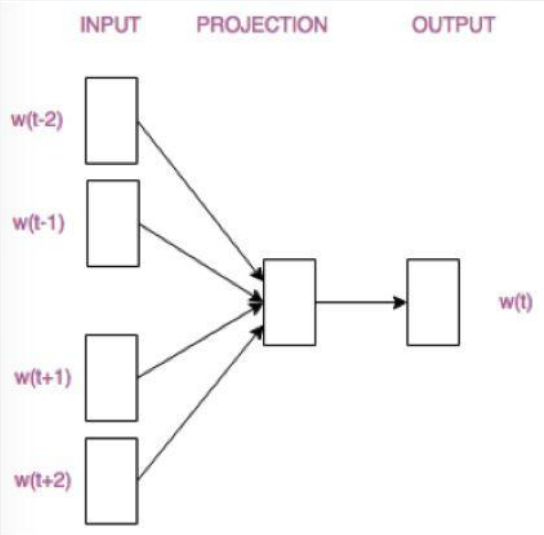
Word2Vec

- 那这个模型是如何定义数据的输入和输出呢?
  - ✓ 两种模型：CBOW、Skip-Gram

4 词嵌入之Word2Vec

CBOW

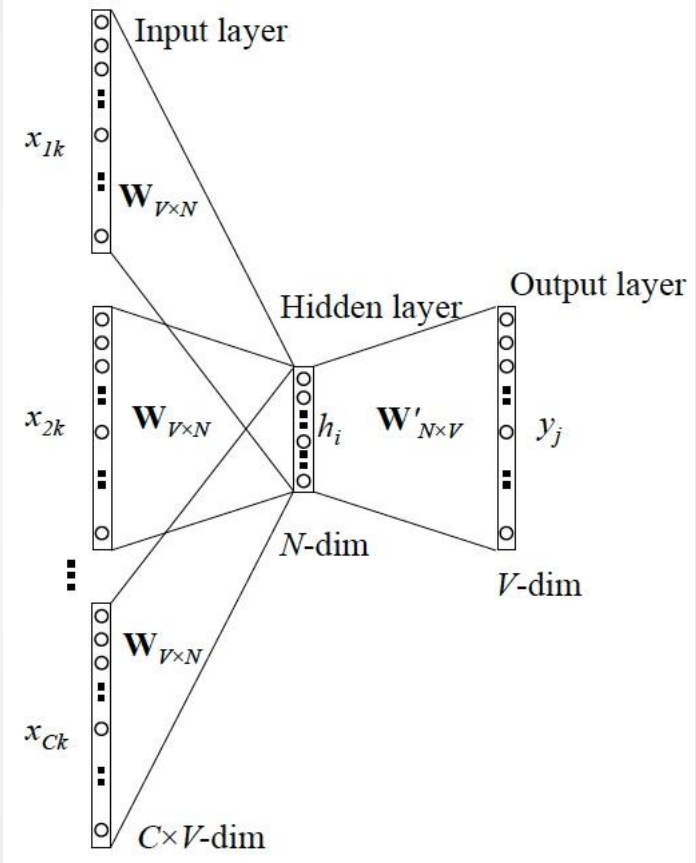
- Continuous Bag-of-Words（简称CBOW）模型：
  - 输入：**某一个特征词**的上下文相关的词对应的词向量
  - 输出：这一特征词的词向量



4 词嵌入之Word2Vec

CBOW

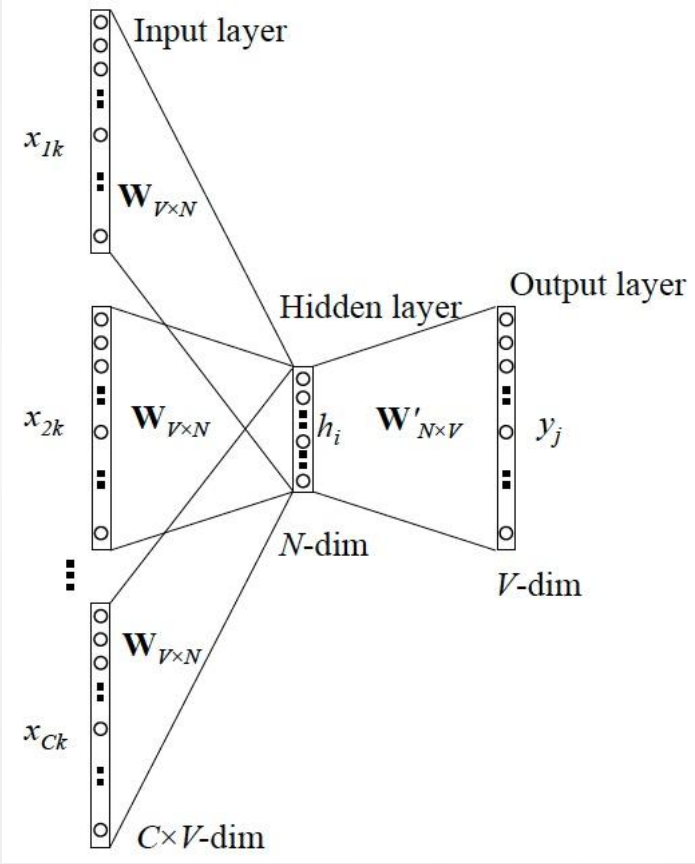
1. 输入层：上下文单词的one-hot. {假设单词向量空间dim为V，上下文单词个数为C}
2. 所有one-hot分别乘以共享的**输入权重矩阵W**. {维度为V x N，N由自己设定，矩阵W随机初始化}
3. 所得的向量相加求平均作为隐层向量.{维度为1 x N}
4. 乘以**输出权重矩阵W'** {维度为N x V}



4 词嵌入之Word2Vec

CBOW

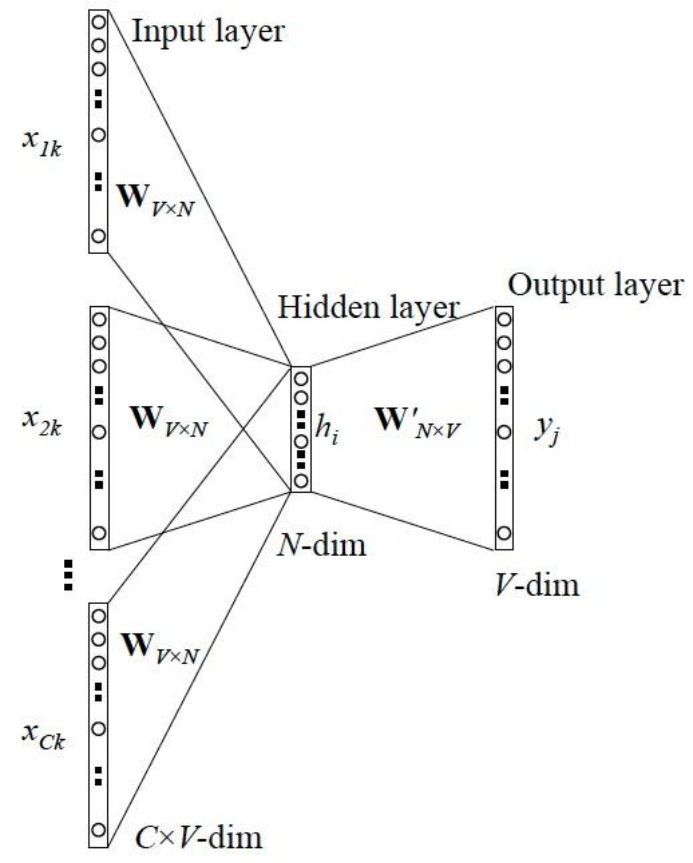
5. 得到向量{1 x V}，激活函数Softmax处理得到V-dim概率分布.{其中的每一维都代表着一个单词}
6. 概率最大的index所指单词为预测出的中间词对应的词向量（target word）
7. 与true label的one-hot做比较，误差越小越好，根据误差更新权重矩阵{定义loss function（一般为交叉熵代价函数），采用梯度下降算法更新**W和W'**}



4 词嵌入之Word2Vec

CBOW

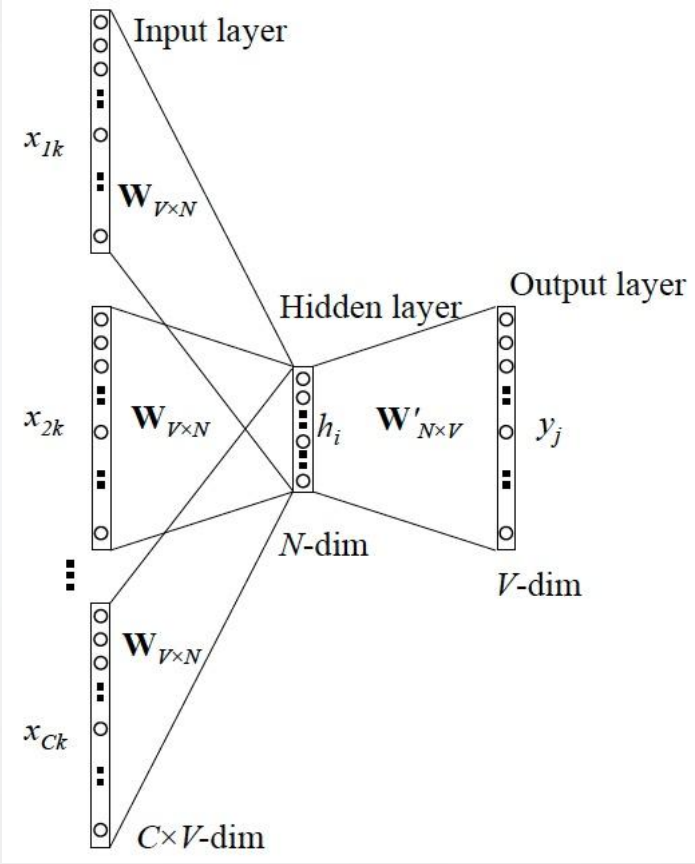
训练完毕后，输入层的每个单词与**矩阵W**相乘得到的向量就是我们想要的词向量。权重矩阵W也叫做look up table。



4 词嵌入之Word2Vec

CBOW

- 也就是说，任何一个单词的one-hot乘以这个矩阵都将得到自己的词向量。
- 有权重矩阵W（look up table）**就可以免去训练过程，而直接查表得到单词的词向量**。
- 其实V x N的权重矩阵W，**每一行就对应了每个单词的词向量**

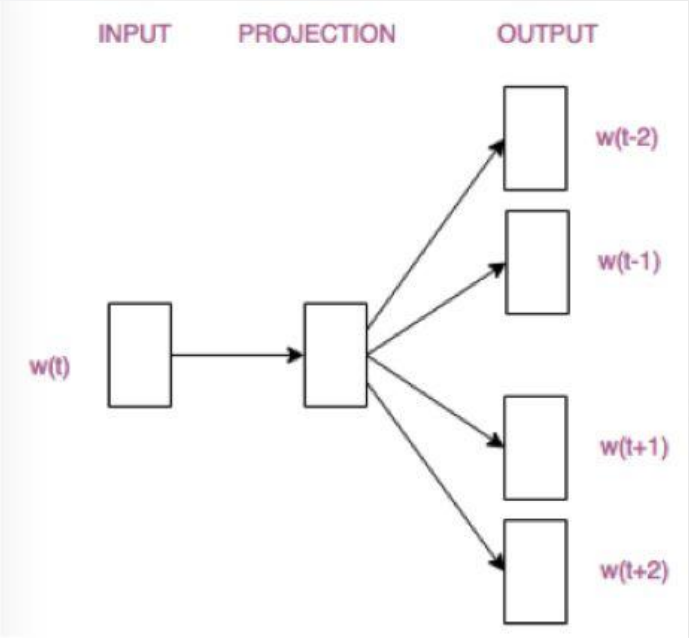


CBOW

- 由于CBOW使用的是词袋模型，因此这4个词都是平等的，也就是不考虑他们和我们关注的词之间的距离大小，只要在我们上下文之内即可。
  - 输入层是4个词向量神经元；
  - 隐藏层的神经元个数我们可以自己指定；
  - 输出是所有词的**softmax概率**（训练的目标是期望训练样本特定词对应的softmax概率最大）。

Skip-Gram

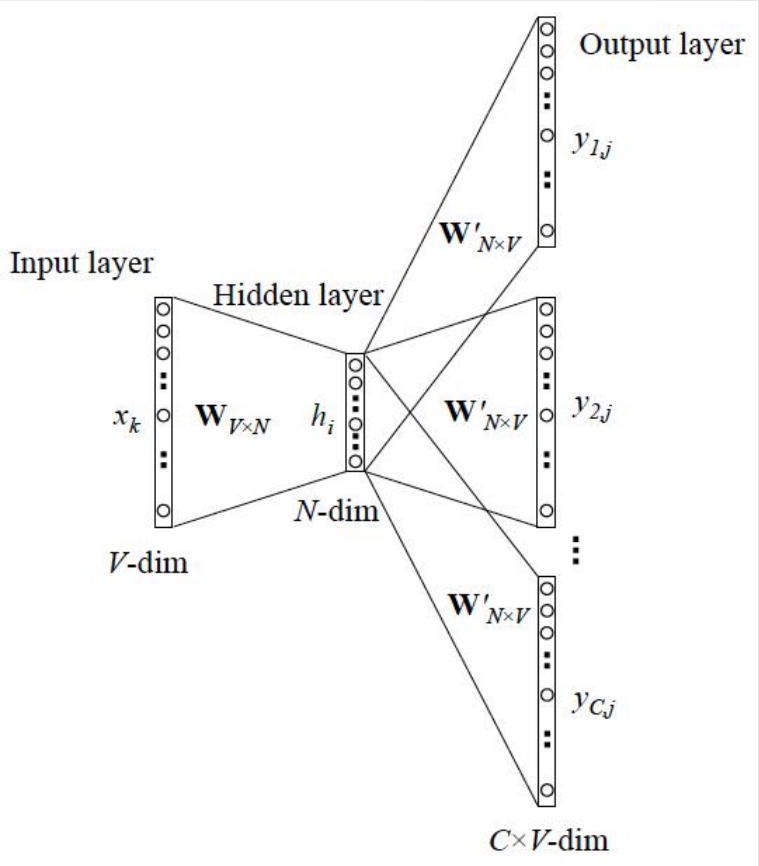
- Continuous Skip-gram模型：
  - 输入：特定的一个词的词向量
  - 输出：特定词对应的上下文词向量



4 词嵌入之Word2Vec

Skip-Gram

- Skip-gram和CBOW的结构类似，只是把整个过程反过来而已。
- 输入中心词x的One-Hot编码，预测它的上下文y。



4 词嵌入之Word2Vec

Skip-Gram

- Skip-Gram模型与CBOW模型的区别仅仅是输入层和输出层不同，权重矩阵W对于词向量的意义是一样的
- 所以对Skip-Gram模型将详细讲解输入层和输出层，中间的正向传播、反向传播过程与CBOW模型没有区别。

Skip-Gram训练时，将中心词与附近的词组成词对，训练集是这些词对的集合（负采样的思想）。

4 词嵌入之Word2Vec

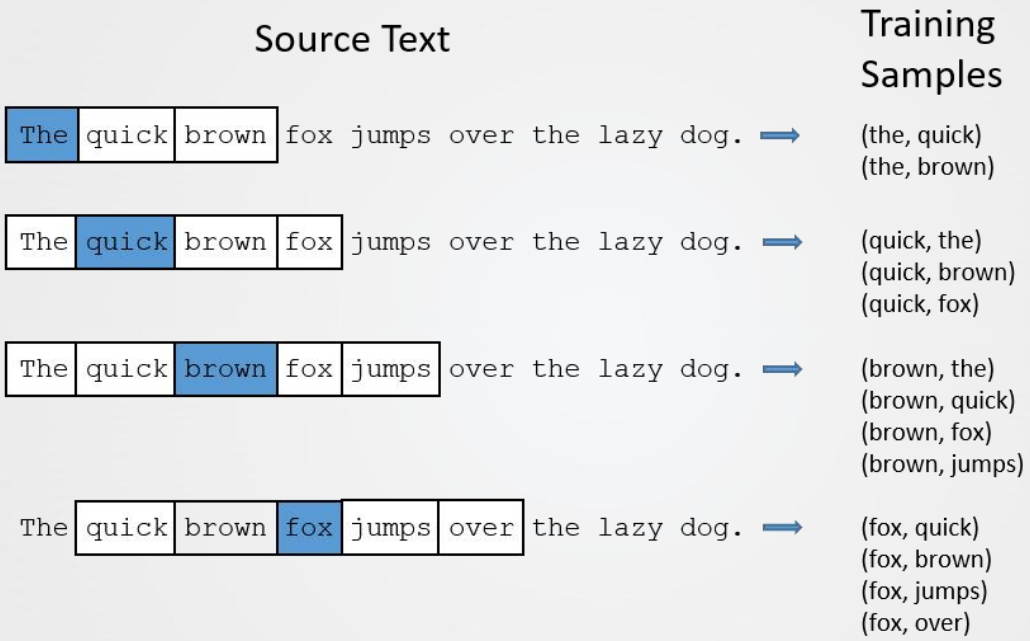
Skip-Gram

- Skip-Gram的思想可以简单叙述为：**给定句子中一个特定的词（input word），随机选它附近的一个词，目标是预测我们选到每个附近词的概率。**
- 根据这个思想，训练数据由特定词和其附近（上下文中）的一个词构成的词对组成，训练集是词对的集合。
- 构造训练集的具体方法如下：

  ✓设定一个**window_size**，表示在**指定词**的前后几个词之内选取**附近词**。之后在这个窗口内选取所有的附近词构成**<指定词，附近词>**词对。

4 词嵌入之Word2Vec

示例



蓝色为指定词（输入词），方框为窗口（window_size = 2）

4 词嵌入之Word2Vec

Skip-Gram

- 模型将通过训练学习这些pair出现的统计概率（从每对单词出现的次数中习得统计结果）；
- 形象地说：我们可能会得到更多类似 <中国，英国> 这样的训练样本对，
- 而对于 <英国，蝈蝈> 这样的组合却看到的很少。
- 因此，当我们的模型完成训练后，给定一个词“中国”作为输入，输出的结果中”英国“或者”俄罗斯“要比”蝈蝈“被赋予更高的概率。

Word2Vec总结（1/4）

- 无论是CBOW模型还是Skip-Gram模型，对于词嵌入而言，所需要的都**仅仅是权重矩阵**，他们的区别在于神经网络模型架构中的输入层与输出层不同。
- 也就是说：词向量来自于参数优化完成后的权重矩阵，而CBOW和Skip-Gram的区别**只是参数优化的指导依据不同而已**。

4 词嵌入之Word2Vec

Word2Vec总结（2/4）

- Word2Vec获得词向量的方法是机器学习领域里一个常见的技巧：
- 训练一个网络来进行预测任务，但是**实际上并没有用这个网络来预测，**而是，利用这个任务（目标）去学习网络中的权重。
- 最终我们需要的、拿走的**是**这个通过训练学习好的**权重矩阵**。

4 词嵌入之Word2Vec

Word2Vec总结（3/4）

- 了解计算机视觉图像领域的同学应该知道**预训练（Pre-training）**的概念，简单概括就是在之前训练得到并保存参数，在之后遇到其他任务时直接使用部分（浅层）已调整好的参数进行fine-tuning。
- 预训练的方法一经提出在图像领域便成为了常规的做法，因为它太有效了。
- 所以我们在NLP领域也这样做了。

4 词嵌入之Word2Vec

Word2Vec总结（4/4）

- 其实**词嵌入就是预训练**：Word2Vec通过训练保存权重矩阵W（提前训练保存参数），在之后进行其他NLP任务时先使用权重矩阵W对文本进行向量化（直接使用调好的参数）。
- 只不过词嵌入相当于只保存第一层参数而图像领域预训练可以保存多层而已。

4 词嵌入之Word2Vec

Word2Vec的优点?

- Word2Vec相对One-Hot等表示方式，考虑到了句子中词与词之间的关系，语义相近的词在向量空间中的距离是相近的。给出一个词，很容易就能找到它的近义词。
- 而训练更新得到矩阵后，实际上相当于把后续工作中的参数矩阵进行了一次预训练，这对很多下游的NLP任务产生了很大的帮助。

4 词嵌入之Word2Vec

Word2Vec存在的问题?

- Word2Vec采用的这种做法就是2018年之前NLP领域里面采用的典型做法，但它是否像图像领域那样一鸣惊人成为NLP领域中的“万金油”呢?



4 词嵌入之Word2Vec

Word2Vec存在的问题?

- 那么问题来了：为什么这样训练及使用Word Embedding的效果没有期待中那么好呢?
- 答： Word Embedding有问题呗。
- 追问： Word Embedding有啥问题？ (Good Question)

4 词嵌入之Word2Vec

Word2Vec存在的问题?

- 这片在Word Embedding头上笼罩了好几年的乌云是什么?
- 是**多义词**问题。
- 我们知道，多义词是自然语言中经常出现的现象，也是语言灵活性和高效性的一种体现。
- 多义词对Word Embedding来说有什么负面影响?

4 词嵌入之Word2Vec

Word2Vec存在的问题?

- Word Embedding在对多义词进行编码的时候，是**区分不开多个含义的**，因为它们尽管上下文环境中出现的单词不同，但是在用语言模型训练的时候，不论什么上下文的句子经过word2vec，都是预测同一个单词；
- 而同一个单词占的是权重矩阵W中同一行的参数空间，这导致两种不同的上下文信息都会**编码到相同的word embedding空间**里去。
- 所以word embedding无法区分多义词的不同语义，这就是它的一个比较严重的问题。

4 词嵌入之Word2Vec

Word2Vec存在的问题?

HOW TO SOLVE

- 有很多研究人员提出很多方法试图解决这个问题，但是从今天往回看，这些方法看上去都成本太高或者太繁琐了，有没有简洁优雅的解决方案呢?

