自 然 语 言 处 理

第6章 文本向量化（下）

授课教师：李芳芳
联系方式：lifangfang@csu.edu.cn

本章教学内容

文本向量化

本章内容一览表（共计4学时）

每小节概要	每小节知识点	重难点
第1小节 前景概要	为什么要进行文本向量化?	否
第2小节 离散表示：词袋模型	四种词袋模型：Onehot、TF、TF-IDF、Ngram	**是**
第3小节 分布式表示：词嵌入	为什么要进行词嵌入?	否
第4小节 Word2Vec	Word2Vec进行文本向量化的原理、优缺点	**是**
第5小节 ELMO模型	ELMO进行文本向量化的原理、优缺点	**是**
第6小节 GPT模型	GPT进行文本向量化的原理、优缺点	**是**
第7小节 课堂小结	内容小结	否

本章教学内容

文本向量化思维导图



5 ELMO的优缺点

- 优点：
  - ✓ 效果好，在大部分任务较传统模型都有一定提升
  - ✓ 解决了以往词向量不能很好表示**“一词多义”**的问题
- 缺点：
  - × 速度较慢，需要通过多层双向LSTM进行训练
  - × ELMO网络架构中**LSTM抽取特征能力远弱于Transformer**（在GPT和Bert中使用）
  - × 拼接方式采用双向融合，特征融合能力偏弱

5 ELMO的优缺点

NLP四大任务

- ✓ 序列标注：分词/语义标注……
- ✓ 分类任务：文本分类/情感计算……
- ✓ 句子关系判断：QA/自然语言推理……
- ✓ 生成式任务：机器翻译/文本摘要……

6 GPT的引入

- 既然ELMO存在这些缺点，那怎么办呢?

- **没事，GPT来啦！！！**

播放视频：大规模预训练语言模型

6 GPT的引入

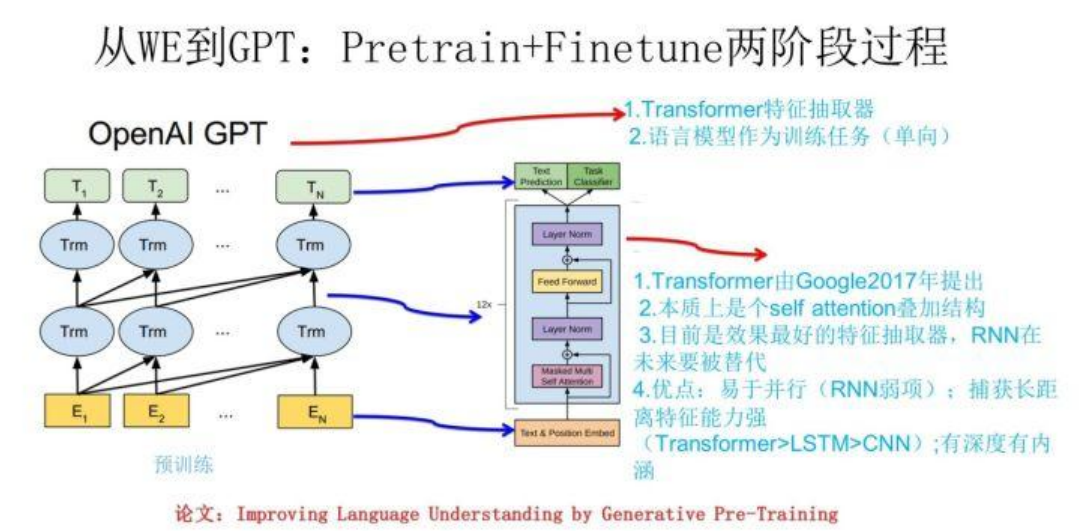
- 如果把ELMO这种预训练方法和图像领域的预训练方法对比，发现两者模式看上去还是有很大差异的。除了以ELMO为代表的这种基于特征融合的预训练方法外，NLP里还有一种典型做法，这种做法和图像领域的方式就是看上去一致的了，一般将这种方法称为“**基于Fine-tuning的模式**”，而GPT就是这一模式的典型开创者。

6 GPT的引入

- GPT是“Generative Pre-Training”的简称，从名字看其含义是指的生成式的预训练。GPT也采用两阶段过程：
- 第一个阶段是利用语言模型进行预训练，第二阶段通过Fine-tuning的模式解决下游任务。

6 GPT第一阶段

- 下图展示了GPT的预训练过程，其实和ELMO类似，主要不同在于两点：***首先，***特征抽取器不是用的RNN，而是用的**Transformer**，它的特征抽取能力要强于RNN，这个选择是很明智的；



6 Transformer简介

- **Transformer**是谷歌在2017年做机器翻译任务的“Attention is all you need”论文中提出的，引起了相当大的反响，很多研究已经证明Transformer提取特征的能力远强于LSTM。
- **Transformer**是个叠加的“自注意力机制（Self Attention）”构成的深度网络，是目前NLP里最强的特征提取器。**注意力机制**在Transformer中被发扬光大，Transformer成为继RNN和CNN之后的又一拔得头筹的特征提取器

6 Transformer简介

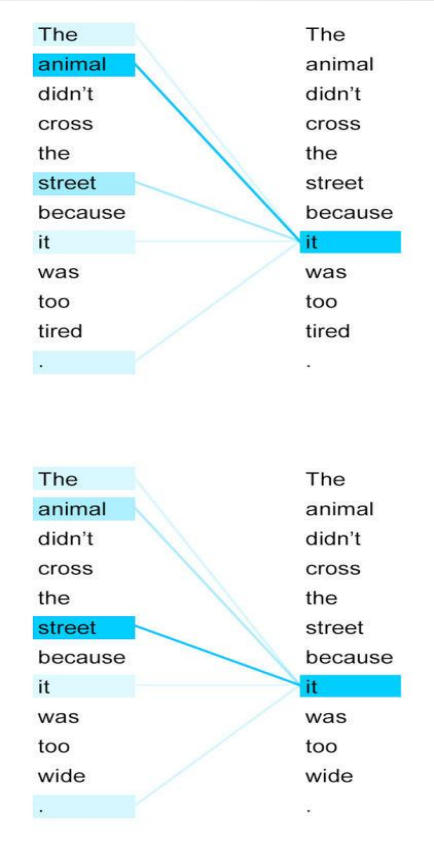
- **GPT主要用到了Transformer的Decoder:**
- Transformer在GPT中扮演的角色类似于LSTM在ELMo中扮演的角色，都是用于抽取特征。但两者使用的方式大不一样。
- 相比于LSTM通过建模时序关系来抽取特征，Transformer通过Self-Attention来并行地计算每个词的特征。

6 Self Attention简介

- **Self-Attention:**

$$Attention(Q,K,V) = softmax\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

- 其中Q, K, V都是通过模型的输入变化而来，可以理解为同一个词的不同形态，除以$\sqrt{d_k}$则是为了归一化，保证训练时的稳定。
- 相比于LSTM需要一个一个计算，Self-Attention可以并行地进行矩阵的运算。并且Self-Attention中每一个词都使用到了整个句子的信息来计算，使用到了丰富的上下文

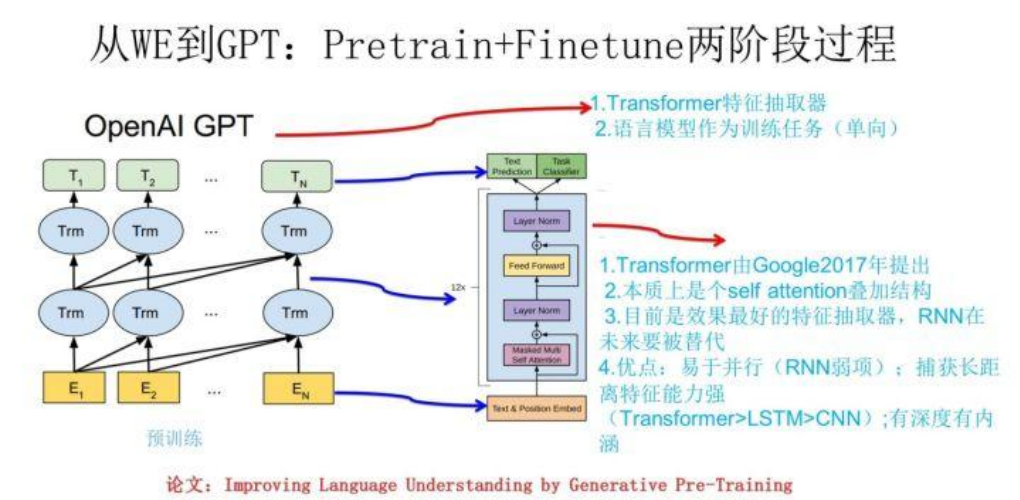


6 Self Attention简介

播放视频：Transformer自注意语言模型

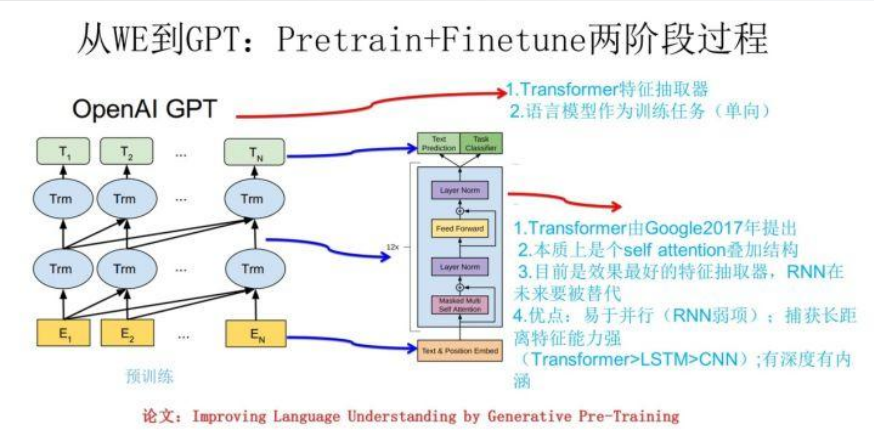
6 GPT第一阶段

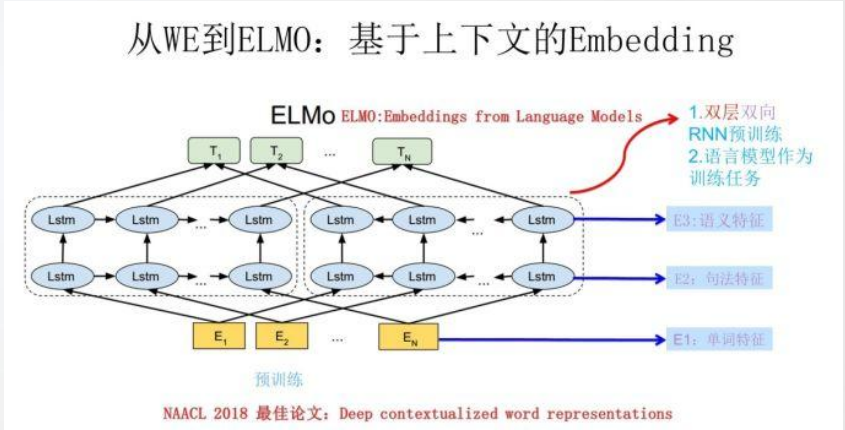
- ***其次，***GPT的预训练虽然仍以语言模型作为目标任务，但采用的是单向的语言模型：模型训练的目标是根据单词的上下文去正确预测单词，之前的单词序列Context-before称为上文，之后的单词序列Context-after称为下文，GPT只采用Context-before来进行预测。



6 GPT和ELMO模型结构对比

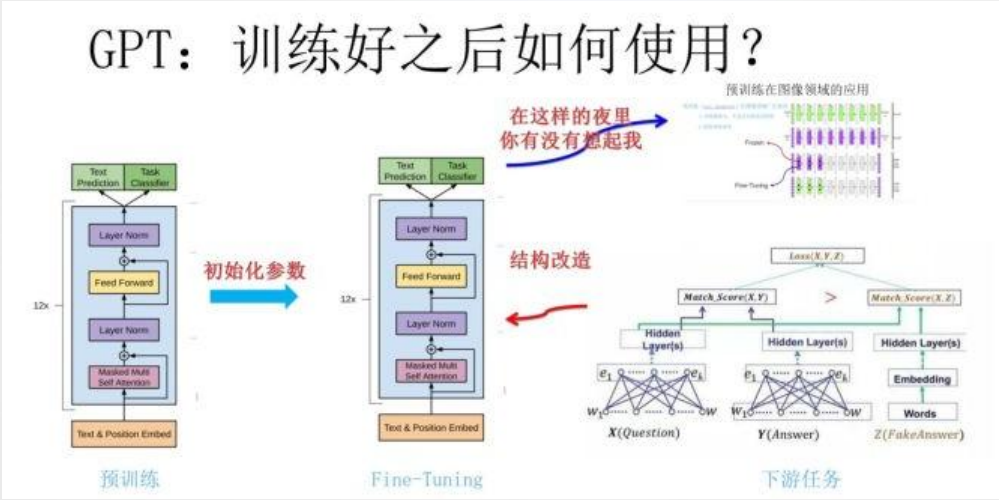
- GPT只采用上文进行预测，ELMo采用上下文
- 特征抽取器：GPT用的**Transformer**，ELMo用的RNN





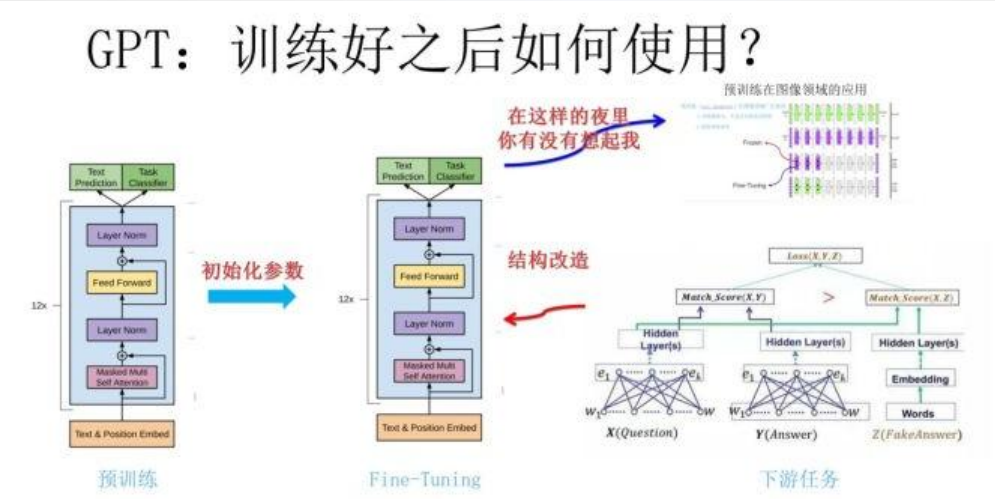
6 GPT第二阶段

- 下图展示了GPT在第二阶段如何使用。首先，对于下游任务来说，**需要把任务的网络结构改成和GPT的网络结构一样**，然后利用第一步预训练好的参数初始化GPT的网络结构，这样通过预训练学到的语言学知识就被引入到手头的任务里来了。



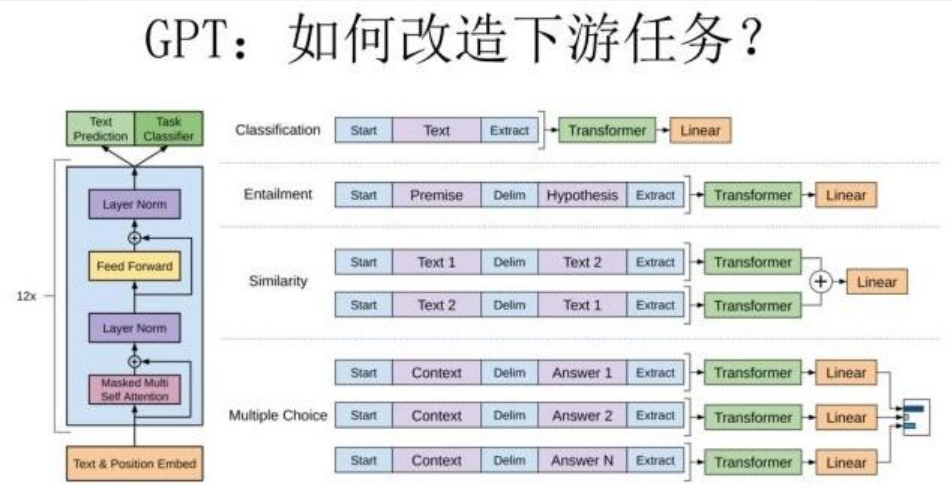
6 GPT第二阶段

- 其次，用手头的任务去训练这个网络，对网络参数进行Fine-tuning，使得这个网络更适合解决手头的问题。
- 可见，GPT与图像领域预训练的过程几乎是一模一样的。



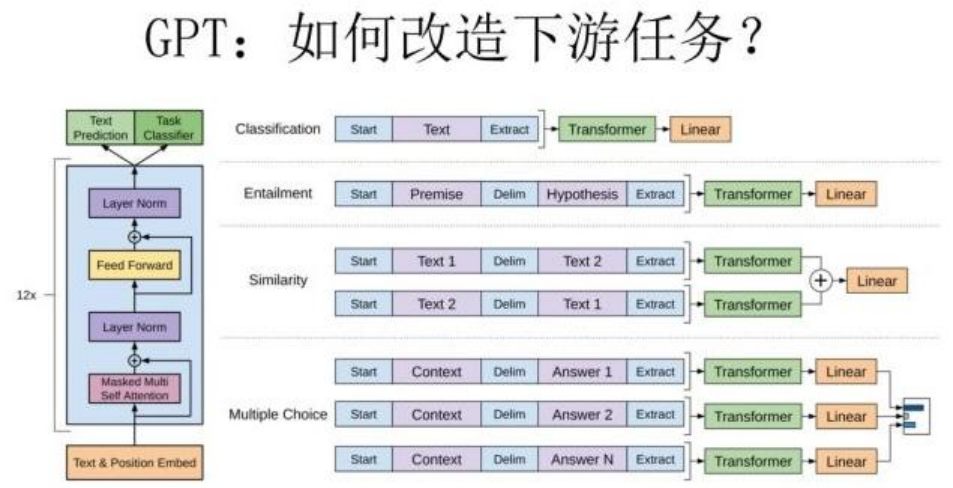
6 改造任务为GPT网络结构

- GPT论文给了一个改造施工图，其实很简单：
  - 对于分类问题，不用怎么动，加上一个起始和终结符号即可；
  - 对于句子关系判断问题，比如Entailment，两个句子中间再加个分隔符即可；



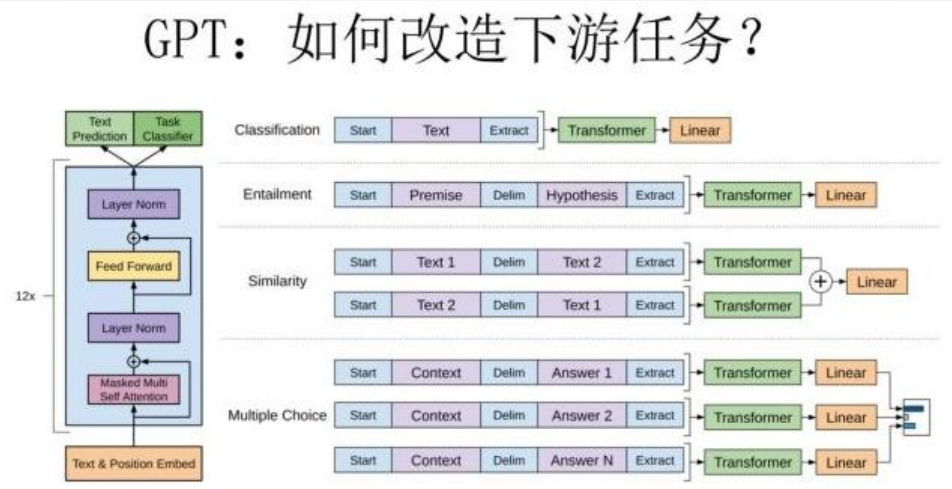
6 改造任务为GPT网络结构

- GPT论文给了一个改造施工图，其实很简单：
  - 对文本相似性判断问题，把两个句子顺序颠倒下做出两个输入即可，这是为了告诉模型句子顺序不重要；
  - 对多项选择问题(多路输入)，每一路把文章和答案选项拼接作为输入。



6 改造任务为GPT网络结构

- 从下图可看出，这种改造还是很方便的，不同任务只需要在输入部分进行修改即可。



6 GPT的效果如何?

- GPT的效果是非常令人惊艳的，在12个任务里，9个达到了最好的效果，有些任务性能提升非常明显。

GPT：效果如何？

Table 2: Experimental results on natural language inference tasks, comparing our model with current state-of-the-art methods. 5x indicates an ensemble of 5 models. All datasets use accuracy as the evaluation metric.

Method	MNLI-m	MNLI-mm	SNLI	SciTail	QNLI	RTE
ESIM + ELMo [44] (5x)	-	-	89.3	-	-	-
CAFE [58] (5x)	80.2	79.0	89.3	-	-	-
Stochastic Answer Network [35] (3x)	80.6	80.1	-	-	-	-
CAFE [58]	78.7	77.9	88.5	83.3		
GenSen [64]	71.4	71.3	-	-	82.3	59.2
Multi-task BiLSTM + Attn [64]	72.2	72.1	-	-	82.1	**61.7**
Finetuned Transformer LM (ours)	**82.1**	**81.4**	**89.9**	**88.3**	**88.1**	56.0

12个NLP任务：9个达到最好效果！

Table 3: Results on question answering and commonsense reasoning, comparing our model with current state-of-the-art methods.. 9x means an ensemble of 9 models.

Method	Story Cloze	RACE-m	RACE-h	RACE
val-LS-skip [55]	76.5	-	-	-
Hidden Coherence Model [7]	77.6	-	-	-
Dynamic Fusion Net [67] (9x)	-	55.6	49.4	51.2
BiAttention MRU [59] (9x)	-	60.2	50.3	53.3
Finetuned Transformer LM (ours)	**86.5**	**62.9**	**57.4**	**59.0**

Table 4: Semantic similarity and classification results, comparing our model with current state-of-the-art methods. All task evaluations in this table were done using the GLUE benchmark. (*mc*= Mathews correlation, *acc*=Accuracy, *pc*=Pearson correlation)

Method	Classification		Semantic Similarity			GLUE
	CoLA (mc)	SST2 (acc)	MRPC (F1)	STSB (pc)	QQP (F1)	
Sparse byte mLSTM [16]	-	**93.2**	-	-	-	-
TF-KLD [23]	-	-	**86.0**	-	-	-
ECNU (mixed ensemble) [60]	-	-	-	81.0	-	-
Single-task BiLSTM + ELMo + Attn [64]	35.0	90.2	80.2	55.5	66.1	64.8
Multi-task BiLSTM + ELMo + Attn [64]	18.9	91.6	83.5	72.8	63.3	68.9
Finetuned Transformer LM (ours)	**45.4**	91.3	82.3	**82.0**	**70.3**	**72.8**

6 GPT的不足之处

- GPT有什么值得改进的地方呢？其实最主要的就是那个**单向语言模型**，如果改造成双向语言模型，后来的**BERT**也就没那么耀眼了。

- GPT使用单向语言模型是个不好的选择，它没有把单词的下文融合进来，这限制了其在更多应用场景的效果。比如阅读理解，在做任务的时候是可以允许同时看到上文和下文一起做决策的，如果预训练时候不把单词的下文嵌入到Word Embedding中，是很吃亏的，白白丢掉了很多信息。

6 GPT的总结

- 播放视频：GPT单向语言模型

7 BERT的引入

- 既然GPT存在这些缺点，那怎么办呢？

- **没关系，BERT来啦。**